

Universidade Federal de Minas Gerais

Nome: Guilherme Vinícius Amorim

O artigo escolhido para a análise crítica é o artigo “*A neural network model for bankruptcy prediction*”, publicado pela IEEE em 15 de Outubro de 2012 e que pode ser acessado pelo seguinte link: [A neural network model for bankruptcy prediction](#).

Introdução

O propósito do estudo em questão é comparar a habilidade de predição de um algoritmo de redes neurais com modelos de análise discriminante multivariada na previsão de risco de falência. Essa área vem sendo estudada ao longo de anos, tendo o primeiro estudo em 1966, no qual tinha-se a intenção de investigar se índices financeiros são capazes de fornecerem informações úteis.

A técnica estatística conhecida como análise discriminante é o método mais usado até hoje para a análise de risco de falência. Assim, uma comparação de um modelo de rede neural e um modelo de análise discriminante, na previsão de falências, faz-se relevante, pois seremos capazes de comparar uma abordagem nova e mais robusta com um método estabelecido que faz suposições a priori sobre as variáveis discriminatórias.

Metodologia

Como o estudo Altman [1968] é utilizado como referência de comparação para estudos subsequentes de classificação de falência, os mesmos índices financeiros usados nessa pesquisa também serão usados no algoritmo de rede neural e na análise discriminante. Esses índices financeiros são:

- Capital de Giro / Ativo Total;
- Lucros Retidos / Ativos Totais;
- Lucro antes dos juros / Impostos ativos totais;
- Valor de mercado do patrimônio / Dívida total;
- Vendas / Ativos totais.

Os dados foram tirados do *Moody's Industrial Manuals* e contém os dados de empresas que entraram em falência entre 1975 e 1982. Essa base de dados conta com 129 empresas: 65 que entraram em falência e 64 que não entraram em falência.

A rede neural utilizada para a comparação foi uma rede Perceptron de três camadas, com saídas classificadas em 0 ou 1, conforme a Figura 1.




Figura 1: Rede Perceptron utilizada no experimento.

O *learning threshold* foi 0.075 e os coeficientes *learning rate* e *momentum* iniciais foram 0.6 e 0.9, respectivamente. Esses dois últimos coeficientes foram ajustados durante o treinamento (Lippmann, 1987) e tiveram valores finais de 0.1 e 0.8, respectivamente. Para o ajuste dos pesos, o método de *backpropagation* foi utilizado. O algoritmo teve um tempo total de 24 horas, com 191,400 interações.

Para a comparação entre os algoritmos, as 129 empresas foram divididas em dois subgrupos: 74 empresas para treinamento e 55 empresas para teste. No primeiro grupo de testes, houve uma proporção 50/50 entre empresas que não faliram e faliram. No segundo grupo de testes, houve uma proporção de 80/20 e no grupo final uma proporção de 90/10 de empresas que não faliram e faliram. A *confusion table* abaixo mostra os resultados obtidos:

Table 1
Comparison of Discriminant Analysis and Neural Networks on Holdout Sample

Training Sample Proportion		50/50		80/20		90/10	
Model	Actual \ Predicted	BR (27)	NBR (28)	BR (27)	NBR (28)	BR (27)	NBR (28)
Neural Network	BR	22 (81.48)	5 (18.51)	21 (77.78)	6 (22.22)	21 (77.78)	6 (22.22)
	NBR	5 (17.86)	23 (82.14)	6 (21.43)	22 (78.57)	4 (14.29)	24 (85.71)
Discrim Analysis	BR	16 (59.26)	11 (40.74)	19 (70.37)	8 (29.63)	16 (59.26)	11 (40.74)
	NBR	3 (10.71)	25 (89.29)	4 (14.29)	24 (85.71)	6 (21.43)	22 (78.57)

BR = Bankrupt, NB = Nonbankrupt, % in parentheses

Conclusão

Analisando os resultados obtidos na *confusion table*, tem-se que a comparação da rede neural Perceptron com o método considerado “lei” em previsão de falências favorece o algoritmo Perceptron, que possui resultados mais robustos que o método de análise discriminante em um experimento com número de amostras reduzido.

Fazendo uma análise crítica do experimento, tem-se que a pesquisa se baseou em somente 5 índices financeiros. Um experimento com mais variáveis envolvidas aproximaria o experimento de um problema real. Ademais, uma comparação envolvendo mais de um algoritmo de rede neural agregaria valor à pesquisa, uma vez que diferentes algoritmos de redes neurais podem ter resultados significativamente diferentes.